


Spatial Transformer

Spatial Transformer Layer



CNN不能很好的处理scaling和rotation

所以需要在CNN之前在嵌入一个spatial transformer layer来对image进行transform
STYE也可以transform feature map

How

- How to transform an image/feature map



$$\text{General layer: } a_{nm}^l = \sum_{i=1}^3 \sum_{j=1}^3 w_{nm,ij}^l a_{ij}^{l-1}$$


$$\text{If we want translate as above: } a_{nm}^l = a_{(n-1)m}^{l-1}$$

$$w_{nm,ij}^l = 1 \text{ if } i = n - 1, j = m \quad w_{nm,ij}^l = 0 \text{ otherwise}$$

(图中表示将图片进行平移)


通过设计不同的 w_{nm}^l (线性变换), 来实现对图片的各种旋转缩放:

Expansion, Compression, Translation



• Rotation

$$\begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$




仿射变换:

$$\begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} a & b \\ c & d \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} + \begin{bmatrix} e \\ f \end{bmatrix}$$

6 parameters to describe the affine transformation

Index of layer l-1

Index of layer l



这个变换只由6个参数表示，所以NN结果就是这六个数

对l层输出feature map中的每个像素 (x, y) ，其值需要从l-1层二点输入feature map中采样(如双线性插值)得到，所以必须通过变换参数将输出坐标 (x, y) 映射到输入坐标 (x', y') ，即回推输入位置

说人话就是回推能保证l层每个像素点都能找到自己在l-1层的位置

将layer l通过transformation变成layer l-1


$$\begin{bmatrix} 1.6 \\ 2.4 \end{bmatrix} = \begin{bmatrix} 0 & 0.5 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} 2 \\ 2 \end{bmatrix} + \begin{bmatrix} 0.6 \\ 0.4 \end{bmatrix}$$

6 parameters to describe the affine transformation

Index of layer l-1

Index of layer l

What is the problem?



变换后的坐标为整数时，能够很好的找到输入像素

但变换后的坐标往往不为整数(如上图)，需要考虑使用双线性插值来估算非整数坐标处的像素值

为什么不用四舍五入(最近邻插值)：

当参数发生微小变换时，变换后的坐标值也发生微小变换，但是四舍五入之后变换消失了，所以取微分的结果几乎永远是0，无法使用GD

Interpolation(插值)


$$\begin{bmatrix} 1.6 \\ 2.4 \end{bmatrix} = \begin{bmatrix} 0 & 0.5 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} 2 \\ 2 \end{bmatrix} + \begin{bmatrix} 0.6 \\ 0.4 \end{bmatrix}$$

Index of layer l-1 Index of layer l

6 parameters to describe the affine transformation

a_{11}^l	a_{12}^l	a_{13}^l
a_{21}^l	a_{22}^l	a_{23}^l
a_{31}^l	a_{32}^l	a_{33}^l

Layer l





$$a_{22}^l = (1 - 0.4) \times (1 - 0.4) \times a_{22}^{l-1} + (1 - 0.6) \times (1 - 0.4) \times a_{12}^{l-1} + (1 - 0.6) \times (1 - 0.6) \times a_{13}^{l-1} + (1 - 0.4) \times (1 - 0.6) \times a_{23}^{l-1}$$

使用双线性插值

找到与求出的坐标值相邻的四个整数坐标，基于距离计算权重，加权平均得到采样值


这样，在参数发生微小变化时，该变化会影响到最终的采样值，就可以使用GD了



ST可以加在任何一个convolution后

Bird Recognition

$$\begin{bmatrix} a & 0 \\ 0 & d \end{bmatrix} \begin{bmatrix} e \\ f \end{bmatrix}$$



鸟类辨识示例：使用两个ST，重点关注鸟类的翅膀和眼睛