


# Optimization(优化)

## gradient descent(梯度下降)

Question: 类神经网络训练不起来


### Adaptive Learning Rate

#### Adagrad



当loss稳定在很小的时候，gradient不一定等于或接近0，可能是在一个坑外反复横跳

Formulation for **one** parameter:



$$\theta_i^{t+1} \leftarrow \theta_i^t - \boxed{\eta} g_i^t$$

$$g_i^t = \frac{\partial L}{\partial \theta_i} \bigg|_{\theta = \theta^t}$$

$$\theta_i^{t+1} \leftarrow \theta_i^t - \boxed{\frac{\eta}{\sigma_i^t}} g_i^t$$

Parameter dependent

当learning rate固定时，不总能很好的满足需求，所以考虑自动修改learning rate

$$\begin{aligned} \theta_i^1 &\leftarrow \theta_i^0 - \frac{\eta}{\sigma_i^0} g_i^0 & \sigma_i^0 &= \sqrt{(g_i^0)^2} = |g_i^0| \\ \theta_i^2 &\leftarrow \theta_i^1 - \frac{\eta}{\sigma_i^1} g_i^1 & \sigma_i^1 &= \sqrt{\frac{1}{2} [(g_i^0)^2 + (g_i^1)^2]} \\ \theta_i^3 &\leftarrow \theta_i^2 - \frac{\eta}{\sigma_i^2} g_i^2 & \sigma_i^2 &= \sqrt{\frac{1}{3} [(g_i^0)^2 + (g_i^1)^2 + (g_i^2)^2]} \\ &\vdots & & \\ \theta_i^{t+1} &\leftarrow \theta_i^t - \frac{\eta}{\sigma_i^t} g_i^t & \sigma_i^t &= \sqrt{\frac{1}{t+1} \sum_{i=0}^t (g_i^t)^2} \end{aligned}$$

6

$$\begin{aligned} \theta_i^{t+1} &\leftarrow \theta_i^t - \frac{\eta}{\sigma_i^t} g_i^t \\ \sigma_i^t &= \sqrt{\frac{1}{t+1} \sum_{i=0}^t (g_i^t)^2} \end{aligned}$$

这样，  
 $g$ 越大， $\sigma$ 越大，learning rate就越小；  
 $g$ 越小， $\sigma$ 越小，learning rate就越大。

## RMSProp

接下来，由于surface error可能会很复杂，我们期望learning rate在同一个参数，同一个方向也能动态变化


$$\begin{aligned}
 \theta_i^1 &\leftarrow \theta_i^0 - \frac{\eta}{\sigma_i^0} g_i^0 & \sigma_i^0 &= \sqrt{(g_i^0)^2} & 0 < \alpha < 1 \\
 \theta_i^2 &\leftarrow \theta_i^1 - \frac{\eta}{\sigma_i^1} g_i^1 & \sigma_i^1 &= \sqrt{\alpha(\sigma_i^0)^2 + (1 - \alpha)(g_i^1)^2} \\
 \theta_i^3 &\leftarrow \theta_i^2 - \frac{\eta}{\sigma_i^2} g_i^2 & \sigma_i^2 &= \sqrt{\alpha(\sigma_i^1)^2 + (1 - \alpha)(g_i^2)^2} \\
 &\vdots & & \\
 \theta_i^{t+1} &\leftarrow \theta_i^t - \frac{\eta}{\sigma_i^t} g_i^t & \sigma_i^t &= \sqrt{\alpha(\sigma_i^{t-1})^2 + (1 - \alpha)(g_i^t)^2}
 \end{aligned}$$

用 $\alpha$ 自己决定之前的 $g$ 和最近的 $g$ 的重要性

## Adam: RMSProp + Momentum

python中有函数，可直接使用

## 出现的其他问题




虽然 $\sigma$ 很小，但会随着积累逐渐变得很大，使step变大，在某个地方并喷；  
但是并喷后又走到 $g$ 很大的地方， $\sigma$ 又变大，使step变小回来

解决方法：

### Learning Rate Scheduling


让 $\eta$ 跟时间有关

#### 1. Learning Rate Decay(Adam常用)



让 $\eta$ 随时间逐渐变小：随着参数更新，离终点越来越近，所以把learning rate减小，使更新能够刹车

## 2. Warm Up(RAdam)



让learning rate先变大后变小

最大要多大、增大速率、何时开始减小之类的都是自己设定

使用Warm Up效果好的可能的解释：一开始的 $\sigma$ 是不精准的，所以先用小 $\sigma$ 在初始位置附近做一些探索，收集统计数据后，再逐渐增大learning rate，到一定程度再减小