


Optimization(优化)

Adaptive Learning Rate


Question: 类神经网络训练不起来

Adagrad



当loss稳定在很小的时候，gradient不一定等于或接近0，可能是在一个坑外反复横跳

Formulation for **one** parameter:



$$\theta_i^{t+1} \leftarrow \theta_i^t - \eta g_i^t$$
$$g_i^t = \frac{\partial L}{\partial \theta_i} \big|_{\theta=\theta^t}$$

$$\theta_i^{t+1} \leftarrow \theta_i^t - \frac{\eta}{\sigma_i^t} g_i^t$$

Parameter dependent

当learning rate固定时，不总能很好的满足需求，所以考虑自动修改learning rate

$$\begin{aligned}
\theta_i^1 &\leftarrow \theta_i^0 - \frac{\eta}{\sigma_i^0} g_i^0 & \sigma_i^0 &= \sqrt{(g_i^0)^2} = |g_i^0| \\
\theta_i^2 &\leftarrow \theta_i^1 - \frac{\eta}{\sigma_i^1} g_i^1 & \sigma_i^1 &= \sqrt{\frac{1}{2} [(g_i^0)^2 + (g_i^1)^2]} \\
\theta_i^3 &\leftarrow \theta_i^2 - \frac{\eta}{\sigma_i^2} g_i^2 & \sigma_i^2 &= \sqrt{\frac{1}{3} [(g_i^0)^2 + (g_i^1)^2 + (g_i^2)^2]} \\
&\vdots & & \\
\theta_i^{t+1} &\leftarrow \theta_i^t - \frac{\eta}{\sigma_i^t} g_i^t & \sigma_i^t &= \sqrt{\frac{1}{t+1} \sum_{i=0}^t (g_i^t)^2}
\end{aligned}$$

6

$$\begin{aligned}
\theta_i^{t+1} &\leftarrow \theta_i^t - \frac{\eta}{\sigma_i^t} g_i^t \\
\sigma_i^t &= \sqrt{\frac{1}{t+1} \sum_{i=0}^t (g_i^t)^2}
\end{aligned}$$

这样，

g 越大， σ 越大，learning rate 就越小；

g 越小， σ 越小，learning rate 就越大。

RMSProp

接下来，由于surface error可能会很复杂，我们期望learning rate在同一个参数，同一个方向也能动态变化

$$\begin{aligned}\theta_i^1 &\leftarrow \theta_i^0 - \frac{\eta}{\sigma_i^0} g_i^0 & \sigma_i^0 &= \sqrt{(g_i^0)^2} \\ \theta_i^2 &\leftarrow \theta_i^1 - \frac{\eta}{\sigma_i^1} g_i^1 & \sigma_i^1 &= \sqrt{\alpha(\sigma_i^0)^2 + (1 - \alpha)(g_i^1)^2} \\ \theta_i^3 &\leftarrow \theta_i^2 - \frac{\eta}{\sigma_i^2} g_i^2 & \sigma_i^2 &= \sqrt{\alpha(\sigma_i^1)^2 + (1 - \alpha)(g_i^2)^2} \\ &\vdots \\ \theta_i^{t+1} &\leftarrow \theta_i^t - \frac{\eta}{\sigma_i^t} g_i^t & \sigma_i^t &= \sqrt{\alpha(\sigma_i^{t-1})^2 + (1 - \alpha)(g_i^t)^2}\end{aligned}$$

用 α 自己决定之前的 g 和最近的 g 的重要性

Adam: RMSProp+Momentum

python中有函数，可直接使用

Adam

- SGDM

$$\begin{aligned}\theta_t &= \theta_{t-1} - \eta m_t \\ m_t &= \beta_1 m_{t-1} + (1 - \beta_1) g_{t-1}\end{aligned}$$



- RMSProp


$$\begin{aligned}\theta_t &= \theta_{t-1} - \frac{\eta}{\sqrt{v_t}} g_{t-1} \\ v_1 &= g_0^2 \\ v_t &= \beta_2 v_{t-1} + (1 - \beta_2) (g_{t-1})^2\end{aligned}$$

$$\theta_t = \theta_{t-1} - \frac{\eta}{\sqrt{\hat{v}_t + \varepsilon}} \hat{m}_t$$

$$\begin{aligned}\hat{m}_t &= \frac{m_t}{1 - \beta_1^t} \\ \hat{v}_t &= \frac{v_t}{1 - \beta_2^t} \quad \text{de-biasing} \\ \beta_1 &= 0.9 \\ \beta_2 &= 0.999 \\ \varepsilon &= 10^{-8}\end{aligned}$$

出现的其他问题

$$\begin{aligned}\theta_i^{t+1} &\leftarrow \theta_i^t - \boxed{\frac{\eta}{\sigma_i^t}} g_i^t \\ \sigma_i^t &= \sqrt{\frac{1}{t+1} \sum_{i=0}^t (g_i^t)^2}\end{aligned}$$




虽然 σ 很小，但会随着积累逐渐变得很大，使step变大，在某个地方井喷；
但是井喷后又走到 g 很大的地方， σ 又变大，使step变小回来

解决方法：

Learning Rate Scheduling


让 η 跟时间有关

1. Learning Rate Decay(Adam常用)



让 η 随时间逐渐变小：随着参数更新，离终点越来越近，所以把learning rate减小，使更新能够刹车

2. Warm Up(RAdam)



让learning rate先变大后变小

最大要多大、增大速率、何时开始减小之类的都是自己设定

使用Warm Up效果好的可能的解释：一开始的 σ 是不精准的，所以先用小 σ 在初始位置附近做一些探索，收集统计数据后，再逐渐增大learning rate，到一定程度再减小